

NYC YELLOW TAXI

Uçtan Uca Büyük Veri Hattı Analizi

- Melis Portakal 220201035
- Batın Erke Öztürk 220201031
- Gülsüm Nur Maslak 220201033
- Halil Han Kavak 220201065

Danışman: Dr. Ayşe Gül Eker — 2025-2026 Bahar

Veri Ölçeği ve Proje Kapsamı

Büyük Veri Hacmi

Ocak 2024 dönemine ait **2.96 Milyon** taksi yolculuk kaydı ile gerçek dünya simülasyonu.

- Milyonlarca satırlık dağıtık veri yönetimi
- Gerçek zamanlı akış simülasyonu

Teknik Hedefler

Modern veri mühendisliği standartlarında bir altyapı inşası:

- **Kafka:** Asenkron veri iletimi
- **Delta Lake:** ACID uyumlu depolama
- **MLflow:** Deney ve model takibi

Pipeline Mimarisi ve Teknoloji Yığını

Sistem, tam izolasyon ve ölçeklenebilirlik için Docker mikroservisleri üzerinde kurgulanmıştır:

- **Konteynerizasyon:** Docker & Docker Compose
- **İşleme:** Kafka & Spark Streaming
- **Depolama & BI:** Delta Lake & Streamlit



Kafka ile Veri Akışı

Bağımsızlaştırma (Decoupling)

Veri kaynağı (Parquet) ile işleme birimi (Spark) arasındaki doğrudan bağımlılık Kafka asenkron topic yapısı ile kesilmiştir.

- **Python Producer:** Veriyi JSON formatına çevirerek mikro-batch'ler halinde akıtır.
- **Scalability:** Topic yapısı yüksek hacimli akışları kesintisiz karşılar.



Veri Saflaştırma: Medallion Architecture

Veri kalitesini kademeli olarak artıran Lakehouse mimarisi:

BRONZE

Ham verinin hiçbir değişikliğe uğramadan kaydedildiği katman.

SILVER

Şema doğrulaması yapılmış ve eksiklerden arındırılmış katman.

GOLD

ML modelleri için optimize edilmiş nihai öznitelik katmanı.

İçgörü Analizi: EDA & Dashboard



Interaktif Dashboard Arayüzü

Saatlik Trend: **18:00 (Peak Hour)** ve Sabah iş giriş saatlerinde yoğunluk zirve yapmaktadır.

Ödeme Türü: Yolculukların **%80'den fazlası** kredi kartı ile gerçekleştirilmektedir.

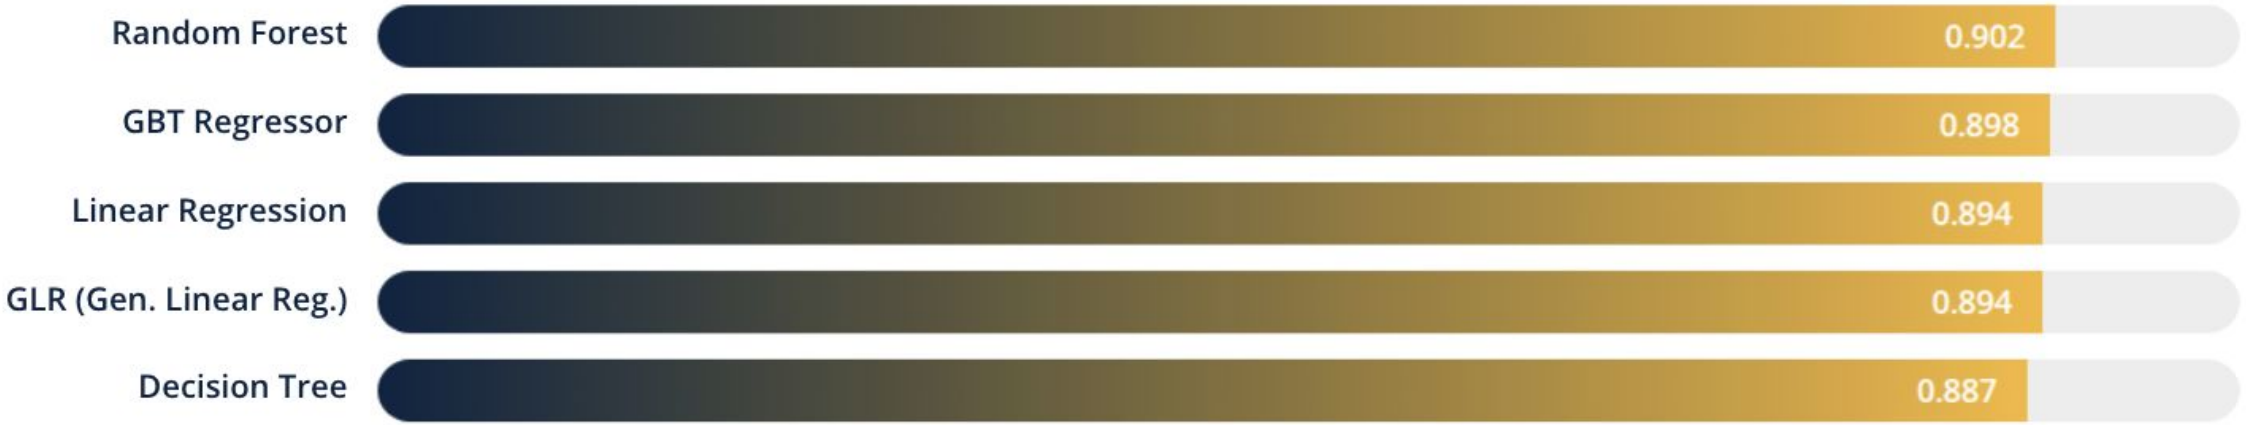
Mesafe: Yolculuk yoğunluğu **2-5 mil** arası kısa mesafeli rotalarda saptanmıştır

Model Performans Karşılaştırması

Model Algoritması	RMSE	MAE	R^2 (Success)
Random Forest Regressor	**6.978**	**2.912**	**0.902**
GBT Regressor	7.132	3.007	0.898
Linear Regression	7.263	3.393	0.894
Generalized Linear Reg. (GLR)	7.263	3.393	0.894
Decision Tree	7.518	3.450	0.887

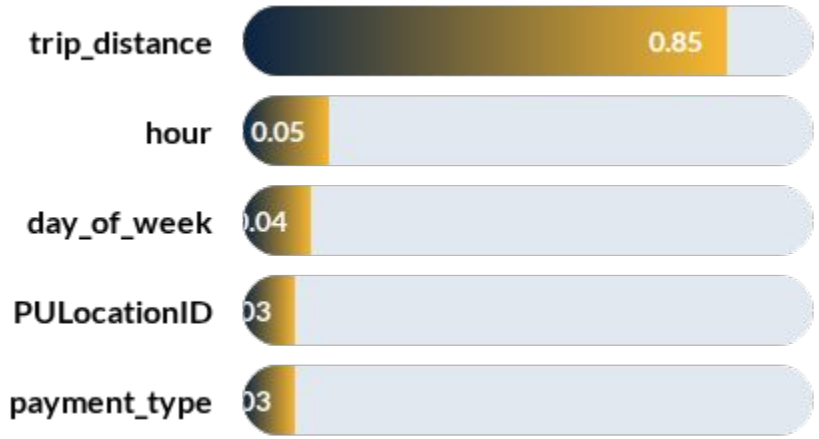
**Tüm metrikler MLflow sunucusu üzerinden objektif olarak takip edilmiştir.*

BAŞARI ANALIZI: R^2 KARŞILAŞTIRMASI



Sonuç: Random Forest modeli, NYC trafiği gibi doğrusal olmayan ilişkileri en iyi hata payıyla yakalayan algoritma olarak **0.902** başarısıyla liderdir.

Öznitelik Önem Düzeyi (Feature Importance)



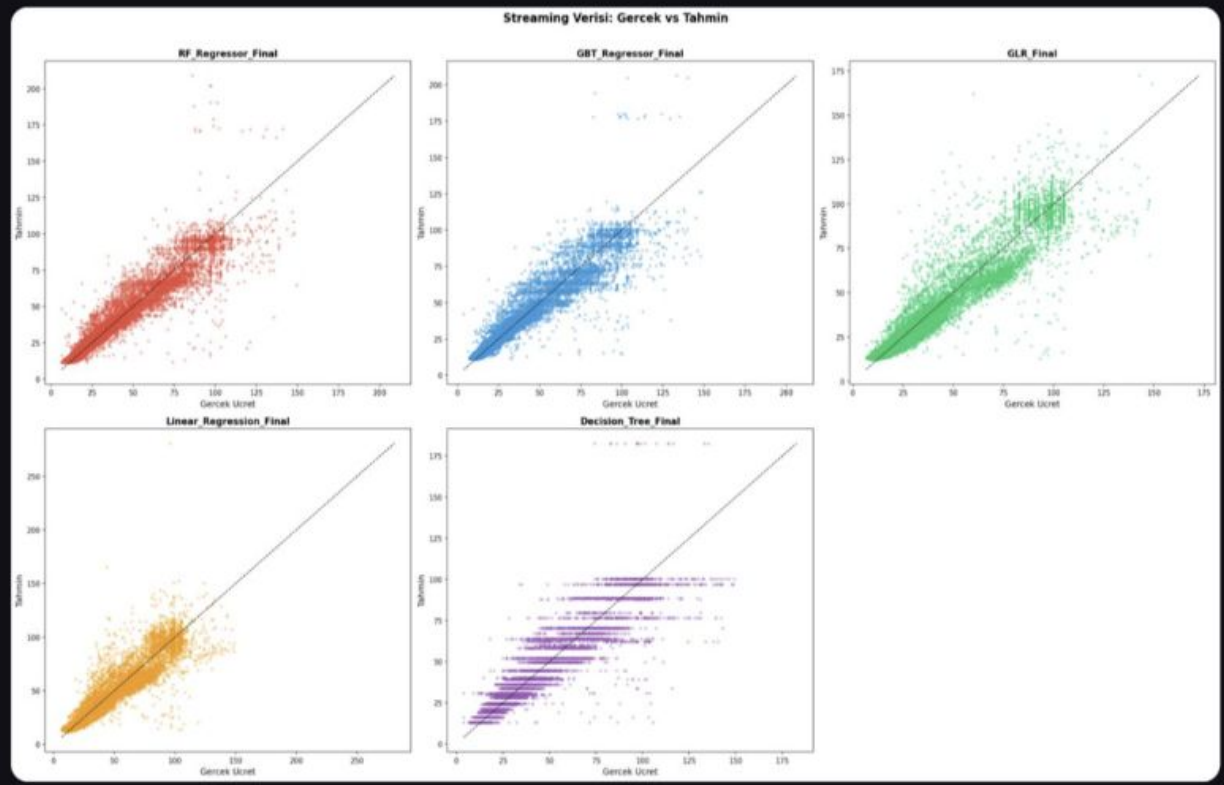
Birincil Belirleyici: Mesafe

Beklendiği üzere **trip_distance** özniteliği, ücret tahmininde %85 ağırlıkla birincil karar vericidir.

Zaman bazlı öznitelikler (saat ve gün) yoğun trafik bekleme sürelerini temsil ederek modeli rafine etmektedir.

STREAMING İZLEME VE HATA ANALIZI

🔍 Streaming Tahmin Analizi (Örnek Model)



Streaming: Gerçek vs Tahmin

Operasyonel İzleme

Spark UI (localhost:4040) üzerinden job progress ve executor sağlığı anlık izlenmiştir.

> **Hata (Residual) Dağılımı:** Tahmin hatalarının normal dağılım sergilemesi, modelin ve pipeline'ın tutarlılığını kanıtlar.

Operasyonel Başarı ve Sonuç



Tam Entegrasyon

Docker, Kafka, Spark ve Delta Lake mimarisi kusursuz senkronize çalışmıştır.



Bilimsel Takip

MLflow ile 5 farklı modelin karşılaştırılması objektif başarıyı getirmiştir.



Ölçeklenebilirlik

Boru hattı anlık veri artışlarını karşılayacak esneklikte simüle edilmiştir.

TEŞEKKÜRLER

NYC Yellow Taxi Big Data Pipeline — 2026

Docker • Kafka • Spark • Delta Lake • MLflow • Streamlit

Gerçek zamanlı büyük veri mimarisi başarıyla simüle edilmiştir.

IMAGE SOURCES



https://imgopt.infoq.com/fit-in/3000x4000/filters:quality(85)/filters:no_upscale()/articles/traffic-data-monitoring-iot-kafka-and-spark-streaming/en/resources/fig1-large.jpg

Source: www.infoq.com



https://gpsolutions.com/wp-content/uploads/2025/11/Frame134663.jpeg

Source: gpsolutions.com



https://i.sstatic.net/Ab74S.png

Source: stats.stackexchange.com



https://images.stockcake.com/public/c/9/a/c9a7a5e8-a217-445c-bdf0-e740903f156c_large/modern-data-dashboard-stockcake.jpg

Source: stockcake.com



https://aboutmurals.ca/wp-content/uploads/2020/12/New-York-Yellow-Taxi-Wallpaper-About-Murals.jpg

Source: aboutmurals.ca